Notas de Optimización

Lorenzo Martinelli

22 de abril de 2026

Resumen

Las presentes notas se basan en el curso de Optimización dictado por Javier Etcheverry en la Facultad de Ciencias Exactas y Naturales de la Universidad de Buenos Aires durante el primer cuatrimestre de 2026.

Índice

1. Introducción 1
   1.1. Condiciones de optimalidad 1
   1.2. Convexidad y funciones convexas 3
      1.2.1. Funciones convexas diferenciables. 4

2. Minimizando funciones. 6
   2.1. Algoritmos de descenso con busquedas lineales. 6
      2.1.1. Minimización unidimesnional. 7

1. Introducción

Dada $f : \Omega \longrightarrow \mathbb{R}$ nuestro objetivo será encontrar un $x^* \in \Omega$ tal que $f(x^*) \leq f(x)$ para todo $x \in \Omega$. Dependiendo de nuestro conocimiento acerca de f y Ω podremos encarar el problema desde distintas perspectivas. Un ejemplo relevante es la optimización convexa (Ω y f convexos), la cual es suficientemente general para abarcar problemas reales y a su vez, nos permite caracterizar su mínimos y dar algoritmos para hallarlos.

§1.1. Condiciones de optimalidad

La idea es comenzar estudiando el caso en que no tenemos restricciones sobre Ω e ir dando condiciones necesarias y suficientes para ser mínimo. Comencemos viendo que significa ser una solución a un problema de *optimización*.

Definición 1. Dado un conjunto Ω y $f : \Omega \longrightarrow \mathbb{R}$ decimos que $x^* \in \Omega$ es un minimizador de f si $f(x^*) \leq f(x)$ para todo $x \in \Omega$.

Definición 2. Dado un conjunto Ω y $f : \Omega \longrightarrow \mathbb{R}$ decimos que $x^* \in \Omega$ es un minimizador local de f si existe un entorno $\mathcal{N} \subset \Omega$ de x^* tal que $f(x^*) \leq f(x)$ para todo $x \in \mathcal{N}$ con $x \neq x^*$.

Para obtener las condiciones necesarias de optimalidad una idea básica es pensar en el comportamiento de la función en alguna dirección dada. Sea $d \in \mathbb{R}^n$ una dirección decimos que es factible si existe $\lambda \in \mathbb{R}$ tal que $x + td \in \Omega$ para todo $0 \leq t \leq \lambda$. Esto nos permite pensar a nuestra función como una función de una variable en el siguiente sentido:

$$\begin{aligned} g &: [0, \lambda] \to \mathbb{R}, \\ t &\mapsto f(x + td). \end{aligned}$$

¿Para qué nos puede interesar esto? Para utilizar cálculo en una variable.

Proposición 1 (Condiciones necesarias de primer orden)**.** Sea $f : \Omega \subset \mathbb{R}^n \to \mathbb{R}$ con $f \in C^1(\Omega)$. Si x^* es un mínimizador local de f en Ω, entonces para cualquier dirección factible $d \in \mathbb{R}^n$ tenemos que $\nabla f(x^*)d \geq 0$.

Demostración. Definiendo g como antes tenemos que tiene un mínimo en $t = 0$. Además, sabemos que

$$g(t) - g(0) = g'(0)t + o(t)$$

donde $o(t)$ es un término que va a cero más rápido que t. Luego, cómo 0 es mínimo para $t \in [0, \lambda]$

$$0 \leq \frac{g(t) - g(0)}{t} = g'(0) + \frac{o(t)}{t}$$

tomando límite con $t \to 0^+$ tenemos el resultado. □

Un caso importante es en el que $x^* \in \Omega$ es un punto interior, cómo cuando $\Omega = \mathbb{R}^n$. En este, toda dirección es factible. En consecuencia, tenemos que $\nabla f(x^*) = 0$ pues dado $d \in \mathbb{R}^n$, d y $-d$ son factibles y por lo que acabamos de ver $\nabla f(x^*)d \geq 0$ y $-\nabla f(x^*)d \geq 0$.

Proposición 2 (Condiciones necesarias de segundo orden)**.** Sea $\Omega \subset \mathbb{R}^n$ y $f \in C^2(\Omega)$. Si x^* es un minimizador local, entonces para cualquier dirección factible d tenemos que:

1. $\nabla f(x^*)d \geq 0$
2. si $\nabla f(x^*)d = 0$, entonces $d^T \nabla^2 f(x^*)d \geq 0$

Demostración. La primer condición ya la probamos, concentremonos en 2. Notemos $\gamma(t) = x + td$ y, $g(t) = f(\gamma(t))$. Tenemos así que

$$g(t) - g(0) = \frac{1}{2} g''(0) + o(t^2)$$

pues $g'(0) = 0$. Luego, diviendo por t^2 y escribiendo quién es g'' obtenemos para t suficientemente chico

$$0 \leq \frac{g(t) - g(0)}{t^2} = d^T \nabla^2 f(x^*)d + \frac{o(t^2)}{t^2}$$

tomando límite en $t \to 0$ tenemos el resultado. □

Vamos ahora a dar algunas condiciones *suficientes* de optimalidad. Primero para el caso general, es decir, el de optimización sin restricciones.

Proposición 3 (Condiciones suficientes de segundo orden - sin restricciones)**.** Sea $f \in C^2$ uan función definida en una región donde x^* es un punto interior. Supongamos además que

1. $\nabla f(x^*) = 0$
2. $\nabla^2 f(x^*)$ es definida positiva.

Luego, x^* es un mínimo local estricto de f.

Demostración. La prueba consiste en recordar que si una matriz es definida postiva entonces existe una constante positiva $a \in \mathbb{R}$ tal que para todo $d \in \mathbb{R}^n$ vale que $d^T \nabla^2 f(x^*)d \geq a\|d\|^2$. Luego, por Taylor,

$$f(x^* + d) - f(x^*) = \frac{1}{2} d^T \nabla^2 f(x^*)d\|d\|^2 + o(\|d\|^2) \geq \frac{a}{2}\|d\|^2 + o(\|d\|^2)$$

donde para $\|d\|$ suficientemente chico el primer termino de la derecha dormindo al segundo y por lo tanto es postivo. □

§1.2. Convexidad y funciones convexas

Los problemas de optimización convexa son los más generales, desde algún punto de vista, sobre los cuales tenemos gran conocimiento acerca de sus soluciones. Ahora, ¿Qué es la *convexidad*?

Definición 3. Decimos que un conjunto Ω es convexo si dados $x, y \in \Omega$ y $\lambda \in [0, 1]$ tenemos que $\lambda x + (1 - \lambda)y \in \Omega$.

Proposición 4. Algunas propiedades básicas de los conjuntos convexos.

1. Dado $K \subset \mathbb{R}^n$ convexo y $a \geq 0$, aK es convexo.
2. Dados $K_1, K_2 \subset \mathbb{R}^n$ conjuntos convexos, entonces $K_1 + K_2$ es convexo.
3. Dados $K \subset \mathbb{R}^n$ convexo, $k + v$ es convexo para todo $v \in \mathbb{R}^n$.
4. Dada una familia de subconjuntos convexos de $\mathbb{R}^n$, $\{K_\alpha\}_\alpha$ se tiene que la intersección $\bigcap_\alpha K_\alpha$ es convexa.

Demostración. Trivial. □

Definición 4. Dado un conjunto $U \subset \mathbb{R}^n$ llamamos capsula convexa al conjunto

$$\{\sum_i^m \lambda_i u_i \ : \ \sum_i^m \lambda_i = 1, \lambda_i \geq 0, u_i \in U\}$$

y lo notamos $\operatorname{conv}(U)$.

Observación 1. Dado $U \subset \mathbb{R}^n$ su cápsula convexa es el menor conjunto convexo que lo contiene.

Definición 5. Una función f definida sobre un conjunto convexo Ω se dice convexa si para todo $x, y \in \Omega$ y, para todo λ entre 0 y 1 vale que

$$f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda) f(y)$$

decimos que f es convexa. Además, si para todo $\lambda \in (0,1)$, $x \neq y$ vale la desigualdad estricta decimos que f es estrictamente convexa.

Observación 2. Nótese que solo tiene sentido hablas de funciones convexas si están definidas sobre conjuntos convexos.

Geométricamente podemos pensar que una función es convexa si dados dos puntos en su gráfico la linea que los une está por encima de este. Vale la pena mencionar que una función f es cóncava si $-f$ es convexa.

Proposición 5. Dadas $f_i : U \to \mathbb{R}$ convexas y $a_i \geq 0$ para todo i entonces $f = \sum_i a_i f_i$ es convexa.

Demostración. Hacer la cuenta... □

Proposición 6. Sea $f : U \subset \mathbb{R}^n \to \mathbb{R}$ convexa, entonces el conjunto $\Gamma_C = \{x \in U \ : \ f(x) \leq C\}$ es convexo para cualquier C.

Demostración. Queremos ver que Γ_C es convexo, tomemos entonces $x, y \in \Gamma_C$, $\lambda \in [0,1]$ y veamos que $z = \lambda x + (1-\lambda)y \in \Gamma_C$ pues $f(z) \leq \lambda f(x) + (1-\lambda) f(y) \leq C$. □

Ejemplo 1 (La norma es convexa)**.** Dado V un espacio vectorial si $\|\cdot\| : V \to \mathbb{R}$ es una norma, entonces es convexa. ¿Por qué? Por la desigualdad triangular. Este resultado nos permite ver que la bola en cualquier norma es convexa.

§1.2.1. Funciones convexas diferenciables.

Proposición 7. Dada $f : \Omega \to \mathbb{R}$ con $f \in C^1(\Omega)$ son equivalentes:

1. f es convexa.
2. Dados $x, y \in \Omega$ se tiene que $f(x) \geq f(y) + \nabla f(y)^t (x - y)$.

Observación 3. Notemos que los roles de x e y en la segunda condición son intercambiables.

Demostración. Veamos primero que 1. implica 2. pues dados $x, y \in \Omega$, dado $\lambda \in [0,1]$ sabemos que

$$f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda) f(y)$$

reescribiendo tenemos que esto es

$$\frac{f(y+\lambda(x-y))-f(y)}{\lambda} \leq f(x)-f(y)$$

consideremos $\phi : [0,1] \to \mathbb{R}$ tal que $\phi(\lambda) = f(y+\lambda(x-y))$. De esta manera tenemos que la expresión anterior se puede escribir como

$$\frac{\phi(\lambda)-\phi(0)}{\lambda} \leq f(x)-f(y)$$

tomando límite con $\lambda \to 0$,

$$\nabla f(y)^t(x-y) = \phi'(0) \leq f(x)-f(y).$$

Nos queda probar ahora que 2. implica 1., tomando $z = \lambda x + (1-\lambda)y$ y utilizando la observación tenemos que

$$\begin{aligned} f(x) &\geq f(z) + \nabla f(z)^t(x-z) \\ f(y) &\geq f(z) + \nabla f(z)^t(y-z) \end{aligned}$$

multiplicando por λ la primer desigualdad, por $1-\lambda$ la segunda y sumando tenemos

$$\begin{aligned} \lambda f(x) + (1-\lambda)f(y) &\geq f(z) + \lambda\nabla f(z)^t(x-z) + (1-\lambda)\nabla f(z)^t(y-z) \\ &= f(z) + \nabla f(z)^t(\lambda x - \lambda z + (1-\lambda)y - (1-\lambda)z) \\ &= f(z) + \nabla f(z)^t(\lambda x + (1-\lambda)y - z) \\ &= f(z) \end{aligned}$$

que es lo que queríamos ver. □

Proposición 8. Sea $f \in C^1(K)$ convexa, entonces

$$\nabla f(x_1)^t(x_2-x_1) \leq \nabla f(x_2)^t(x_2-x_1)$$

para todo $x_1, x_2 \in K$.

Demostración. Sabemos, o deberíamos saber, que dados $x_1, x_2 \in K$

$$\begin{aligned} f(x_2) &\geq f(x_1) + \nabla f(x_1)^t(x_2-x_1) \text{ y,} \\ f(x_1) &\geq f(x_2) + \nabla f(x_2)^t(x_1-x_2) \end{aligned}$$

de esta manera,

$$\begin{aligned} f(x_2) - f(x_1) &\geq \nabla f(x_1)^t(x_2-x_1) \text{ y,} \\ f(x_2) - f(x_1) &\leq \nabla f(x_2)^t(x_1-x_2) \end{aligned}$$

uniendo ambas desigualdades obtenemos el resultado. □

Proposición 9. Si $K \subset \mathbb{R}^n$ es convexo y $f \in C^2(K)$. Son equivalentes:

1. f es convexa.
2. $\forall x_1, x_2 \in K$ tenemos que $d^t\nabla^2 f(x_1)d \geq 0$ donde $d = x_2 - x_1$.

Demostración. 2. $\implies$ 1. Por Taylor sabemos que

$$f(x_2) = f(x_1) + \frac{1}{2}\nabla f(x_1)^t d + d^t\nabla^2 f(\xi)d$$

con ξ una combinación convexa de x_1, x_2. La idea ahora es notar que $d = t(x_2-\xi)$, con $t \geq 0$. De esta manera,

$$d^t\nabla^2 f(\xi)d = t^2(x_2-\xi)\nabla^2 f(\xi)(x_2-\xi) \geq 0.$$

Luego, f es convexa.

2. $\implies$ 1. Fijemos x_1 en K y definamos $g(x) = f(x) - \nabla f(x_1)^t x$ y, notemos que g tiene un mínimo en x_1. Además,

1. $\nabla g(x_1) = 0$.
2. $\nabla^2 g(x_1) = \nabla^2 f(x_1)$.

Luego,

$$0 \leq g(x) - g(x_1) = \frac{1}{2}(x - x_1)^t \nabla^2 f(x)(x - x_1) + o(\|x - x_1\|),$$

tomando $x = t(x_2 - x_1) + x_1$, si $t \in (0, 1)$ entonces $x \in K$ y,

$$0 \leq g(x) - g(x_1) = \frac{t^2}{2}(x_2 - x_1)^t \nabla^2 f(x)(x_2 - x_1) + \frac{o(t^2)}{t^2},$$

diviendo por t^2 y tomando límite con $t \to 0$ tenemos el resultado. □

2. Minimizando funciones.

El objetivo de este capítulo – y de esta materia – es minimizar funciones. Considero relevante comenzar con un ejemplo sencillo que muestre qué tipo de métodos aparecen minimizando funciones. Supongamos entonces que queremos minimizar $q(x) = \frac{1}{2}x^t Gx - b^t x + c$. Podemos suponer que G es simétrica, sino basta cambiarla por $\frac{1}{2}(G + G^t)$. ¿Qué sabemos de esta función?

- $\nabla q(x) = Gx - b$,
- $\nabla^2 q(x) = G$.

Esto nos dice que, en caso de existir, un punto crítico x^* satisface que $Gx^* = b$. Cuando $b \in$ subespacio generado por las columnas de G esto tiene solución y, es única cuando G es inversible.

Supongamos ahora que $G > 0$, una idea para minimizar es considerar la dirección de máximo descenso en un punto x_k que viene dada por

$$d_k = -\nabla q(x_k) = -g_k,$$

y dar un paso de cierta longitud α_k en esa dirección,

$$x_{k+1} = x_k + \alpha_k d_k$$

e iterar. A esto lo llamamos *algoritmo de descenso*. En este caso, podemos aprovechar que sabemos que es una función cuadrática, veamos. Si definimos $h(\alpha) = q(x_k + \alpha d_k)$ sabemos que es una parábola que viene dada por,

$$h(\alpha) = \frac{1}{2}\alpha^2 d_k^t G d_k + \alpha d_k^t G x_k + \frac{1}{2} x_k^t G x_k - b^t x_k - \alpha b^t x_k + c$$

Esta tiene un mínimo en α^* si $h'(\alpha^*) = 0$, esto es

$$\alpha^* d_k^t G_k d_k + d_k^t G x_k - b^t d_k = \alpha^* d_k^t G_k d_k + d_k^t (G x_k - b) = \alpha^* d_k^t G_k d_k + d_k^t g_k,$$

Tomando $\alpha_k = \alpha^*$ podemos considerar,

$$\begin{cases} x_{k+1} = x_k - \alpha_k g_k \\ \alpha_k = \dfrac{-g_k^\top g_k}{g_k^\top G\, g_k} \end{cases}$$

tenemos así nuestro algoritmo para minimizar. ¿Es útil? No, pero aporta valor teórico para comprender los métodos de descenso.

§2.1. Algoritmos de descenso con busquedas lineales.

Queremos un algoritmo que siempre converja y, en lo posible, a un minimizador local. ¿Cómo? Empiezo en un x_0 e itero eligiendo direcciones de descenso y moviendome adecuadamente a lo largo de ellas.

§2.1.1. Minimización unidimensional.

Estudiemos el caso de una función $f : [a, b] \to \mathbb{R}$ unimodal, es decir, una función con único minimizador local. Formalmente, f es unimodal si existe $x^* \in [a, b]$ tal que f es decreciente en $[a, x^*]$ y creciente en $[x^*, b]$.

Supongamos que nos dan N valuaciones de f, la pregunta que nos hacemos es si existe una manera óptima de elegir donde valuar. Queremos poder decidir en que intervalo está x^* con mínima incerteza. En general, dados $a_k < c_k < d_k < b_k$.

$$\begin{cases} a_{k+1} = a_k \text{ y, } b_{k+1} = d_k & \text{si } f(c_k) < f(d_k) \\ a_{k+1} = c_k \text{ y, } b_{k+1} = b_k & \text{caso contrario.} \end{cases}$$

Esta idea está bien, pero ¿Y si en lugar de en cada paso elegir dos nuevos puntos no reutilizamos alguno de los anteriores? El método de fibonacci propone elegir c_k, d_k de la siguiente manera:

$$\begin{cases} c_k = b_k - \dfrac{F_{N-k-1}}{F_{N-k}}(b_k - a_k) \\ d_k = a_k - \dfrac{F_{N-k-1}}{F_{N-k}}(b_k - a_k) \end{cases}$$

Con esta elección obtenemos que $b_{N-1} - a_{N-1} = \frac{1}{F_N}(b_0 - a_0)$. Donde $F_N \approx \Phi^N$ y $2\Phi = 1 + \sqrt{5}$ Una versión low cost del algoritmo consiste en reemplazar $\frac{F_{N-k-1}}{F_{N-k}}$ por $\frac{1}{\Phi}$.